Compiladores y lenguajes formales

Tema 4. Expresiones regulares

Universidad Europea

Tema 4. Expresiones regulares

Índice

Tema 4. Expresiones regulares

1. Presentación

El objetivo de este tema es aprender qué son las expresiones regulares, así como a operar con ellas. También aprenderemos a implementar un analizador léxico utilizando una herramienta generadora de analizadores léxicos, denominada **Flex,** de acceso libre.

Para ello seguiremos el siguiente índice:

- Expresiones regulares.
- Operaciones con expresiones regulares.
- Definiciones regulares, precedencia y asociatividad.
- Implementación de un analizador léxico con Flex.
- Secciones de un programa Flex.
- Ejemplo de analizador léxico.
- Errores más comunes con Flex.

Se probará a generar un analizador léxico básico con Flex, con la idea de ir ampliándolo de acuerdo con la gramática que se decida para el compilador.

2. Expresiones regulares

Se corresponden con las **gramáticas de tipo 3 de la jerarquía de Chomsky.** Las expresiones regulares son una forma de especificar **patrones,** entendiendo por patrón la forma de describir cadenas de caracteres. Es la forma de definir los ***tokens*** **o componentes léxicos** y, como veremos, cada patrón concuerda con una serie de cadenas.

De esta forma, utilizamos las expresiones regulares para darle nombre a estos patrones.

El lenguaje que se reconoce mediante estas expresiones regulares **(r)** se denomina **lenguaje generado por la expresión regular L(r)** (Louden, 2004).

Recordando la siguiente tabla:

Tabla 1. Expresiones regulares

Token (componente léxico)	Lexema	Patrón
Identificador	a, valor, b	[a-zA-Z]+
Número	5, 3,25, 56	[0-9+(\.[0-9]+)?

Vemos que para describir un identificador que se define solo por letras utilizando el patrón [a-zA-Z]+, que reconoce cualquier letra mayúscula o minúscula seguido del símbolo +, estamos indicando que al menos tiene que haber una letra para describir un identificador, pero no hay límite para el número de caracteres que puede tener ese *token* (identificador).

Una expresión regular se puede construir a partir de otras expresiones regulares más simples. Cuando definamos los símbolos mediante los que se especifican las expresiones regulares veremos ejemplos de estos, definiendo letras y dígitos y como un identificador es una combinación de ambos.

Para definir las expresiones regulares usamos **metacaracteres** o **metasímbolos** que especifican las acciones que se pueden reconocer sobre un determinado carácter o símbolo. Algunos de estos metacaracteres son: *****, **+**, **?**, **|**.

Cuando queremos utilizar estos símbolos, como por ejemplo * con su significado normal, para la operación de multiplicar se utiliza un carácter de escape que anula el significado especial del metacarácter. En este ejemplo la forma correcta sería *, y así tenemos el símbolo de multiplicar en un patrón.

3. Operaciones con expresiones regulares

Hay tres operaciones básicas con expresiones regulares:

1. **Selección entre alternativas.** Se denota por el metacarácter **|**. Ejemplo: a|b, significa que puede ser a o b. Esta operación equivale a la unión, puesto que tanto a como b valdrían como lexemas para este patrón (obsérvese que utilizamos patrón y expresión regular de forma indistinta).

2. **Concatenación.** Se construye poniendo un símbolo al lado del otro y no utiliza ningún metacarácter. Ejemplo: ab, significa que el lexema equivalente tiene que ser "ab", sin alternativa posible.

3. **Repetición.** También se la denomina cerradura de Kleene y se denota por el matacarácter *. Identifica una concatenación de símbolos incluyendo la cadena vacía, es decir "0 o más instancias" del símbolo afectado. Ejemplo: a^* significa que los lexemas para este patrón podrían ser: λ, a, aa, aaa, aaaa,…

Además de estas operaciones básicas, aparecieron posteriormente extensiones a las mismas para cubrir algunas lagunas a la hora de especificar patrones:

- Una o más repeticiones. Se denota por el metacarácter +, también se le denomina cierre positivo. Esta operación indica que el símbolo afectado tendrá una o más instancias. Ej.: a+ significa que los lexemas para esta expresión regular podrían ser: a, aa, aaa, aaaa, …

- Cero o una instancia. Se denota por el metacarácter ?, y significa cero o una ocurrencia del símbolo afectado. Ej. a? significa que los lexemas que podrían valer son: λ o a. Describe a un símbolo opcional.

- Intervalo de caracteres. Para especificar un intervalo de caracteres todos ellos válidos, podríamos usar la alternativa o utilizar los corchetes y un guión. Ej: [a-z] significa cualquier carácter de la a a la z, que también se podría haber especificado por a|b|c|d y así sucesivamente hasta la z, pero esta forma es mucho más abreviada y evita errores. También se pueden incluir los intervalos múltiples [a-zA-Z], que representa todas las letras minúsculas y mayúsculas.

- Clases de caracteres. Es como el intervalo, pero sin el guion y sirve también para abreviar las alternativas. Ej.: [abc], equivale a a|b|c.

- Cualquier carácter. Se denota por un punto ., sirve para expresar que cualquier carácter encaja con la expresión regular. Se suele utilizar al final de la especificación de un analizador léxico por si queremos hacer alguna acción para todo lo que no concuerde con los patrones definidos.

- Cualquier carácter que no pertenezca a un conjunto. Se denota por ^. O también por la tilde ~, y significa cualquier carácter distinto a los que está afectando el metacarácter. Ej: [^a] significa cualquier carácter que no sea a.

4. Definiciones regulares, precedencia y asociatividad

Con el objeto de simplificar la **notación,** se pueden poner nombres a las expresiones regulares, con el objeto de no tener que volver a escribir la expresión cada vez que tenemos que utilizarla. Por tanto, una definición regular es, a modo de ejemplo:

Letra =[a-zA-Z] Dígito =[0,9]

Figura 1. Definición regular.

Pudiendo reutilizarlas para definir otro concepto, como por ejemplo:

- Identificador = letra (letra|digito)*, donde queremos decir que un identificador una cadena que comienza por una letra a la que le pueden seguir 0 o más letras (minúsculas o mayúsculas) o dígitos. Ejemplo de lexemas serían: a, a3, a3b123. Los paréntesis sirven para indicar que todo lo que está incluido entre ellos se verá afectado por el metacarácter, en este caso el *, que implica 0 o más repeticiones.

Otro aspecto importante de las expresiones regulares es la **precedencia y la asociatividad**. Está basada en la convención de que el orden de precedencia de mayor a menor es: **repetición (*, +, ?), concatenación y alternativa** y todas son asociativas por la izquierda.

También es importante tener en cuenta los paréntesis, si queremos tener una precedencia diferente para determinados símbolos afectados por ellos. Como nos indica Louden (2004) en su ejemplo, (a|b) c, la operación alternativa tiene mayor precedencia que la concatenación al estar afectada por los paréntesis. La norma es igual que en matemáticas, donde (5 - 2) * 4 = 3*4 = 12, la operación afectada por los paréntesis se realiza antes (tiene mayor precedencia) que la multiplicación, aunque sea una resta.

5. Implementación de un analizador léxico con Flex

Se han desarrollado herramientas para construir analizadores léxicos a partir de expresiones regulares. Un ejemplo de este tipo es **LEX** escrito por Mike Lex y Eric Schmidt, que en su versión libre se denominó Flex (Fast Lex).

Aprenderemos a utilizar las expresiones regulares, combinándolas con acciones para reconocer los símbolos de un lenguaje.

Posteriormente lo combinaremos con el analizador sintáctico para generar el embrión de un compilador.

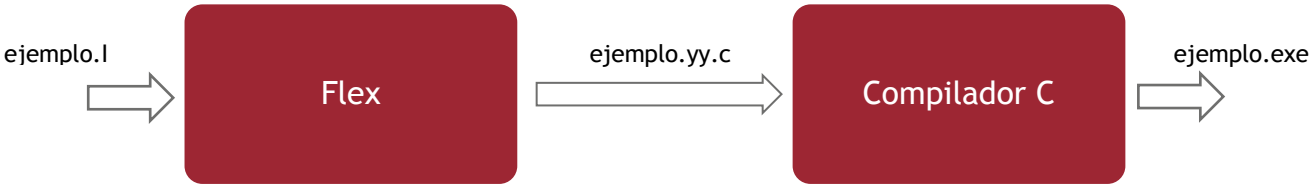

Figura 2. Embrión de un compilador

El proceso es el siguiente:

- **Primero.** Se escribe con un editor de texto (por ejemplo, Notepad) una especificación del analizador léxico mediante un programa denominado ejemplo.l, en lenguaje Flex.
- **Segundo.** Después ejemplo.l, se ejecuta con Flex para producir el programa en C, ejemplo.yy.c (Flex ejemplo.l).

  Este programa construye una representación en forma de tabla de diagrama de transiciones que se construye a partir de las expresiones regulares definidas en ejemplo.l. Las acciones asociadas a las expresiones regulares de ejemplo.l se convierten en código escrito en C y se transfieren a ejemplo.yy.c.
- **Tercero.** Compilamos ejemplo.yy.c con el compilador de C y obtenemos el programa ejecutable ejemplo.exe.

6. Secciones de un programa Flex

Un programa en Flex tiene tres partes o secciones, separadas por una línea con %%.

La sección de declaraciones: son los #include, #define, declaración de variables (que serán globales), etc. que se copian tal cual en la cabecera del fichero "nombre_lex.lex.c". Son previas al uso del reconocimiento de símbolos.

Tiene cuatro partes.

1. **Código de usuario.** #include, #define y va delimitada por%{…..%}.

2. **Directivas de funcionamiento del Flex.** Cambian el funcionamiento por defecto de Flex y las más comunes son:

   - %option noyywrap: permite usar Flex sin necesidad de definir varios ficheros de entrada. Sirve para hacer varias pasadas. Cuando llega al final del fichero, se llama a esta función que devuelve un 1 o un 0, volviendo al principio del fichero para volver a tratarlo en función de ese valor.

   - %option case-insensitive: considera las mayúsculas y minúsculas como el mismo carácter.

   - %yylineno: permite guardar el número de línea que está procesando.

3. **Definiciones regulares.** Permite dar nombre a patrones complejos, como por ejemplo, DIGITO [0-9].

4. **Condiciones de arranque.** Permiten modificar el flujo de análisis y las hay de dos tipos:

   - Inclusivas (%s variable): son evaluados los patrones con la condición de arranque que no utilizan ninguna condición.

   - Exclusivas (%x comentario): se evalúan solo los que cumplen la condición de arranque.

Partes del programa en Flex

Tabla 2. Partes del programa en Flex.

Declaraciones
%%
Reglas
%%
Código de usuario

Sección de reglas

Esta sección contiene reglas con el formato **PATRÓN ACCIÓN**, donde cada acción es un fragmento de programa que describe cual ha de ser la acción que realizará el analizador léxico cuando el patrón concuerde con un lexema del fichero que contiene el código fuente.

En los patrones se pueden utilizar **expresiones regulares, definiciones regulares y condiciones de arranque.** En el ejemplo que realizaremos en este tema el analizador léxico trabajará solo, pero normalmente trabaja de forma sincronizada con el analizador sintáctico, por tanto **ACCIÓN** devolverá el control al analizador sintáctico.

Condiciones de arranque

Las condiciones de arranque son un mecanismo que tiene Flex para activar reglas condicionalmente (véase Flex, 1995).

Las acciones son código C (es importante subrayar que todas las variables que se declaren antes de la primera regla serán locales a la rutina que hace el escaneo).

Una vez se reconoce un patrón o expresión regular, su valor está en **yytext:**

Ejemplo de patrón-acción: [abc] {printf ("%s", **yytext**); return(abc) ;}

¿Cómo se identifican los patrones cuando pueden aplicarse varias reglas?

1. Se aplica el patrón que concuerda con el número mayor de caracteres de la entrada si hay dos patrones que concuerdan con el mismo número de caracteres en la entrada, entonces se aplica el que esté definido primero.

Ejemplo

Entradas

Tenemos la siguiente entrada **xyz:**

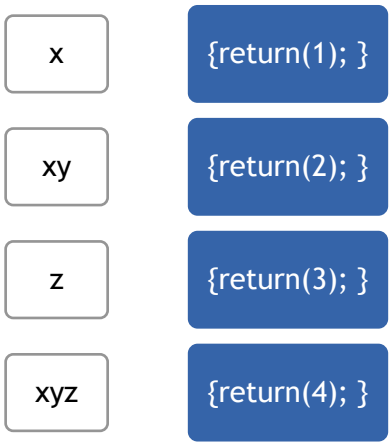

En este caso entraremos por la última regla, puesto que es el patrón más largo que concuerda con la entrada, aplicando por tanto la regla 1. Flex incorpora una serie de variables para almacenar el lexema (yytext) y realizar acciones con sus valores (además de para comunicarse con el analizador sintáctico).

Tabla 3. Variables para almacenar el lexema

Variable	Tipo	Descripción
yytext	Char* o char []	Contiene la cadena de texto del fichero de entrada que ha encajado con la expresión regular descrita en la regla.
yyleng	int	Longitud de yytext Yylenght=strlen (yytext)
yyin	FILE*	Referencia al fichero de entrada.
Yyval yylval	struct	Contienen la estructura de datos de la pila con la que trabaja Bison o Yacc (son los generadores de analizadores sintácticos). Sirve para el intercambio de información entre ambas herramientas.

Sección de código de usuario: el código que se escribe en esta sección se traslada de forma íntegra al fichero nombre_flex.yy.c.

Esta sección es opcional y, si no se escribe, es equivalente a escribir lo siguiente:

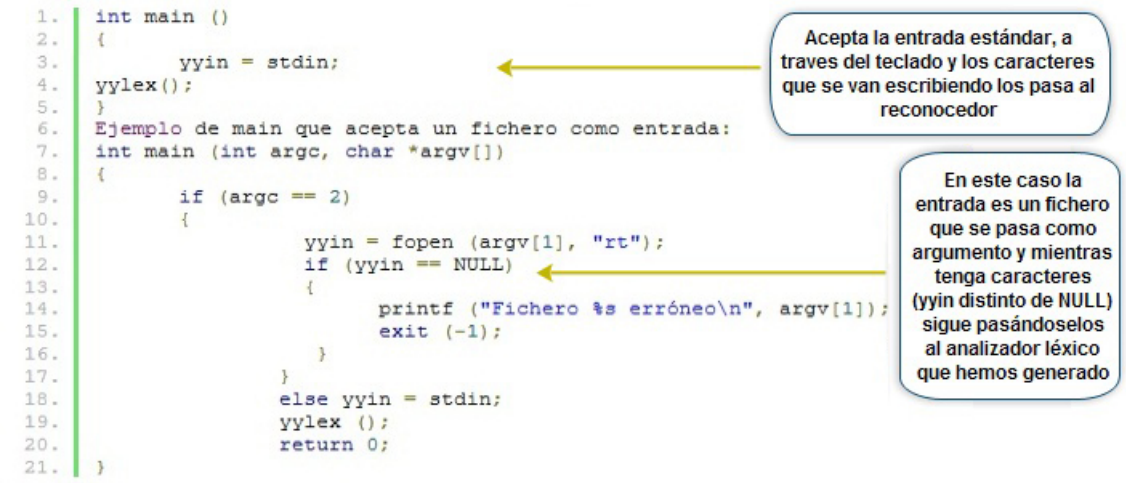

Figura 2. Sección de código de usuario

7. Ejemplo de analizador léxico

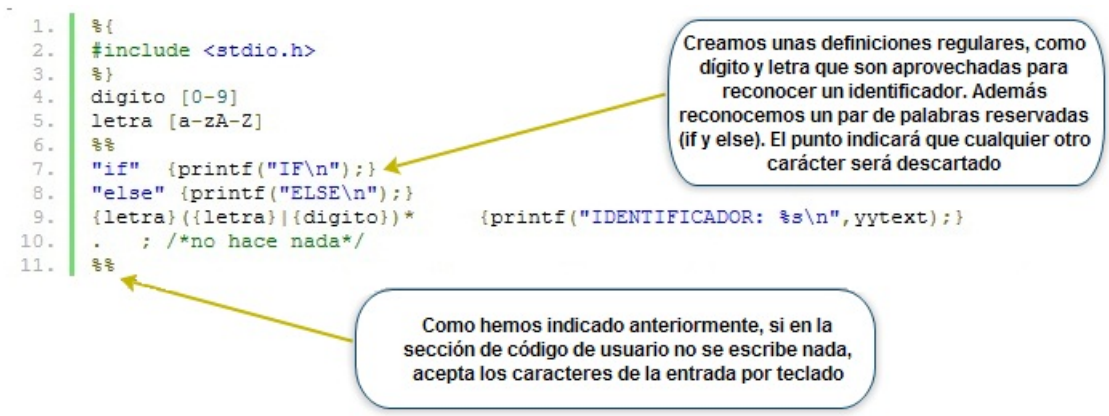

Figura 3. Ejemplo de analizador léxico.

Si no le ponemos nada más, permitirá que salga por la salida estándar (pantalla) y acepte caracteres por la entrada estándar (teclado).

Una vez funcione, se le puede incorporar el código de usuario visto anteriormente que permite que se le pueda pasar un fichero con el código fuente a reconocer. El proceso de compilación es el siguiente:

- **Primero.** Editamos ejemplo.l, con el código indicado en esta pantalla (para posteriormente ir ampliando).
- **Segundo.** flex ejemplo.l, obtendremos ejemplo.yy.c
- **Tercero.** gcc -o ejemplo.exe ejemplo.yy.c

8. Resumen

En este tema hemos entendido qué son y para qué sirven las expresiones regulares, cómo funciona un analizar léxico y cómo se relaciona con el analizador sintáctico y con otras estructuras necesarias como la tabla de símbolos. Para hacernos una idea más completa, hemos visto todas las funciones que debe llevar a cabo el analizador léxico con el fichero de entrada que contiene el código fuente. Además, hemos conocido que ventajas aporta a un compilador.

Más adelante hemos comprendido cuáles son los conceptos básicos (*token* o componente léxico, lexema y patrón), donde hemos aprendido que un *token* puede tener uno (palabra reservada u operadores) o infinitos (identificadores o números) lexemas.

Por otro lado, hemos entendido cómo funciona el analizador léxico y cómo se construye a partir de una expresión regular el autómata finito que lo soporta. Estos conceptos los trataremos en mayor detalle en los dos próximos temas.

También se ha conocido cómo se diseña un analizador léxico por medio de una tabla o un diagrama de transiciones, representando de esta forma los estados por los que pasa el analizador para reconocer un *token*.

Posteriormente, hemos aprendido mediante un ejemplo a reconocer un identificador, y esto puede extenderse a los números enteros, números decimales, operadores, comentarios, etc. Además, se han identificado tres formas de implementar estos ejemplos; generador de analizadores léxicos, lenguaje de alto nivel y lenguaje de bajo nivel.

Para finalizar, hemos visto los errores léxicos que se pueden detectar y la forma de tratarlos para eliminar esos errores o minimizar su impacto en el resto del compilador.

Referencias bibliográficas

La bibliografía referencia para el seguimiento de la asignatura es:

Aho A.V., Lam M. S., Sethi R. y Ullman J.D.(2008) *Compiladores, principios, técnicas y herramientas* (2ª Edición). Perason Educación. México. ISBN: 978-970-26-1133-2.

Louden K.C. (2004), *Construcción de Compiladores: Principios y práctica*. Thomson Learning. Mexico. ISBN: 970-686-299-4.

Otras fuentes recomendadas son:

Aho A.V., Sethi R. y Ullman J.D. (1986). *Compiladores principios, técnicas y herramientas*. AddisonWesley Publishing Company. Traducción de 1990 por Addison-wesley Iberoamericana, S. A.

Isasi P., Martínez P., Borrajo D. (1997). *Lenguajes, Gramáticas y Autómatas. Un enfoque práctico*. Addison-Wesley.